

## R high performance programming

Aloysius Lim, William Tjhi (著) 唐李洋(译)





## 注解:

修改时复制copy-on-modification:

即从已有对象创建新的对象有时并不需要占用额外内存

//检查对象大小
object.size()
pryr包的object\_size()
//查看对象所指内存块
pryr包的address()
//追踪对象复制方法
tracemem()


运行时计算值部分 实例 -- 层次聚类

//方法1:计算每对观察值的距离矩阵然后决定哪一对最近

```
A<-matrix(rnorm(1E5),1E4,10)
dist mat<-as.matrix(dist(A))</pre>
diag(dist mat)<-NA
res1<-which(dist mat==min(dist mat,na.rm=T),arr.ind=T)[1,]
obiect size(A)
##800k
object size(dist mat)
##801MB
//距离矩阵需要成倍的内存空间存储所有观察对的距离
//方法二:可以逐对计算,需要内存少,但时间长
library(pdist)
temp_res<-lapply(1:nrow(A),function(x){</pre>
temp<-as.matrix(pdist(X=A,Y=A[x,]));</pre>
temp[x]<-NA;
output_val<-min(temp,na.rm=T);
output_ind<-c(x,which(temp==output_val));
output<-list(val=output val,ind=output ind);
})
val vec<-sapply(temp res,FUN=function(x) x$val)</pre>
ind_vec<-sapply(temp_res,FUN=function(x) x$ind)</pre>
res2<-ind vec[,which.min(val vec)]</pre>
object_size(temp_res)
##2.72MB
object_size(val_vec)
##80kB
object size(ind vec)
##80.2kB
(1)方法2在实际应用可以采用FNN包的knn();
(2)代码并行化:用parallel包的parLApply()代替lapply()
                                                         整型代替数值型

─ 更小的数据类型

                                                         字符串改成因子向量
                                                稀疏矩阵 matrix(n,m,n,sparse=T)
                               使用节约内存的数据结构 目
                                                对称矩阵 matrix包的as(A,"dspMatrix")
  chapter 7 使用有限的内存处理大型数据第
                                                比特向量 bit包的as.bit(A)
                                                       bigmemorv包
                               使用内存映射文件并以块的形式处理数据
rep.int(x,times):整型
object.size(rep.int("0123456789",1e6))
##8000096 bytes
object.size(rep.int(formatC(seq_len(1e3),width=10),1e3))
object.size(formatC(seg len(1e6),width=10))
##64000040 bytes
字符型向量存储指向包含实际数据的其他向量的指针;需要的存储量取决于向量中唯一字符
串的个数。
```



```
集群节点运行同一任务
#衡量串行算法的运行时间
#L'Ecuyer组合多递归生成器
RNGkind("L'Ecuyer-CMRG'")
nsamples<-5e8
lambda<-10
system.time(random1<-rpois(nsamples,lambda)</pre>
#在集群上生成随机数
#将这个任务平均分配到worker上
cores<-detectCores()
cl<-makeCluster(ncores)</pre>
samples.per.process<-</pre>
diff(round(seq(0,nsamples,length.out=ncores+1)))
#在基于socket的集群上生成随机数之前,每个worker需要不同的种子来生成随机数流
clusterSetRNGStream(cl)
system.time(random2<-unlist(
parLapply(cl,samples.per.process,rpois,lambda)))
stopCluster(cl)
集群节点运行不同任务
RNGkind("L'Ecuyer-CMRG'")
nsamples<-5e7
pois lambda < -10
system.time(random1<-
list(pois=rpois(nsamples,pois.lambda),unif=runif(nsamples),norm=rn
orm(nsamples),exp=rexp(nsamples)))
cores<-detectCores()
cl<-makeCluster(cores)</pre>
calls<-
list(pois=list("rpois", list(n=nsamples, lambda=pois.lambda)), unif=l
ist("runif", list(n=nsamples)), norm=list("rnorm", list(n=nsamples))
exp=list("rexp",list(n=nsamples)))
clusterSetRNGStream(cl)
system.time(random2<-parLapply(cl,calls,function(call)</pre>
{do.call(call[[1]],call[[2]])}))
stopCluster(c)
```

```
在关系型数据库中使用SQL进行数据预处理
                                                  PostGRESQL/RPostgreSQL包
                           将R表达式转化为SQL
                                        PivotalR 仅支持PostGRESQL和Pivotal (Greenplum)数据库 目
  chapter 9 将数据处理交给数据库系统
                           在数据库中运行统计和机器学习算法

    MADlib (尚不支持windows)

                           使用列式数据库提升性能 目
                           使用数据库阵列最大化科学计算的性能 目
dplvr包
library(dplyr)
db.conn<-
src_postgres(dbname="rdb",host="hostname",port=5432,user="ruser",p
assword="rpassword")
#创建两个到数据表sales和trans items的引用
sales.tb<-tbl(db.conn,"sales")</pre>
trans items.tb<-tbl(db.conn,"trans items")</pre>
#inner ioin()联结sales和trans items表
joined.tb<-inner join(sales.tb,trans items.tb,by="trans id")</pre>
#group by()根据客户ID对项目分组
cust.items<-group by(joined.tb,cust id)</pre>
cust.spending<-summarize(cust.items,spending=sum(price))</pre>
cust.spending<-arrange(cust.spending,desc(spending))</pre>
cust.spending<-select(cust.spending,cust id,spending)</pre>
#collect()用于运行SQL语句并获取结果
custs.by.spending<-collect(cust.spending)
top.custs<-head(cust.spending,10L)</pre>
#dplyr包提供%>%将操作联结起来,前面可以写为
top.custs<-sales.tb%>%inner_join(trans_items.tb,by="trans_id")
%>%grouped by(cust id)%>%summarise(spending=sum(price))
%>%arrange(desc(spending))%>%select(cust id,spending)%>%head(10L)
PivotalR包
library(PibotalR)
db.conn<-
db.connect(host="hostname",port=5432,dbname="rdb",user="ruser",pas
sword="rpassword")
sales.tb<-db.data.frame("sales",db.conn)</pre>
trans_items.tb<-db.data.frame("trans_items",db.conn)
#执行SQL并获取结果
lookat(count(sales.tb$cust id))
```

#content方法查看数据库服务器执行的SOL查询

```
content(max(trans items.tb$price))
trans<-by(trans items.tb['price'],trans_items.tb$trans_id,sum)
sales.value<-
merge(sales.tb[c("trans id","cust id","store id")],trans,by="tran-
s id")
cust.sales<-by(sales.value,sales.value$cust id,function(x){</pre>
trans count<-count(x$trans id)</pre>
total spend<-sum(x$price sum)
stores visited<-count(x$store id)</pre>
cbind(trans_count,total_spend,stores_visited)})
names(cust.sales)<-</pre>
c("cust_id","trans_count","total_spend","stores_visited")
lookat(cust.sales,5)
使用列式数据提升性能
MonetDB(https://www.monetdb.org/Downloads)
windows选择开始 | 程序 | MonetDB | 启动服务器,初始化并启动服务器。
library(MonetDB.R)
db.drv<-MonetDB.R()
db.conn<-
dbConnect(db.drv,host="hostname",post=50000,dbname="rdb",user="mon
etdb",password="monetdb")
dbWriteTable(db.conn,"sales",sales)
dbWriteTable(db.conn,"trans_items",trans.items)
library(microbenchmark)
microbenchmark({res<-dbGetQuery(db.conn,'SELECT
store id, SUM(proce) as total sales FROM sales INNER JOIN tran-
s items USING (trans id) GROUP BY strore id;')},times=10)
使用数据库阵列最大化科学计算的性能
1、下载安装SCIDB
2、在SCIDB服务器安装shim
3、从CRAN安装scidb包
library(scidb)
scidbconnect(host="hostname",port=8080)
#使用as.scidb()将数据装载到数据库
A<-as.scidb(matrix(rnorm(1200),40,30),name="A")
B<-as.scidb(matrix(rnorm(1200),30,40),name="B")
#scidb提供类似r的语法来操纵SCIDB矩阵和数组
                              hadoop分布式文件系统
                     几个概念
                              MapReduce: 以数据并行的方式处理存储在HDFS的数据的框架
  chapter 10 R和大数据
                     Amazon Web Services上配置Hadoop
                     R上的hadoop包:rhdfs/rmr2/plyrmr/rhbase/ravro/RHIPE/datadr/Trelliscope
```